爬虫期中作业

爬虫程序

豆瓣电影top

```
from lxml import etree
  import requests
 import MySQLdb
 def get_movies(i):
  #设置请求头
  headers={
  'user-agent':'Mozilla/5.0 (Windows NT 6.1;Win64;x64) ApplewebKit/537.36 (KHTML,like Gecko)
  Chrome/52.0.2743.82 Safari/537.36',
   'Host':'movie.douban.com'
  movie_list=[]
  for a in range(i):
      link='https://movie.douban.com/top250?start='+ str(a*25)
      r \!\!=\! requests.get(\texttt{link}, \texttt{headers} \!\!=\! \texttt{headers})
      s = etree.HTML(r.text)
      All_movie = s.xpath('//*[@id="content"]/div/div[1]/ol/li')
      for Movie in All_movie:
          conn=MySQLdb.connect(host='localhost',
                                 user='dxj',
                                  passwd='a81877568',
                                 db='oa'.
                                 charset='utf8')
          cur=conn.cursor()
          M_name=Movie.xpath('./div/div[2]/div[1]/a/span[1]/text()')
          name=",".join(map(str, M_name))
          M_star=Movie.xpath('./div/div[2]/div[2]/div/span[2]/text()')
          star=",".join(map(str, M_star))
          \label{eq:m_href_Movie.xpath} $$ M_href=Movie.xpath('./div/div[2]/div[1]/a/@href') $$
          href=",".join(map(str, M\_href))
          #将数据插入相应的电影表中
          movie_list.append(M_name)
          cur.execute(sql)
          cur.close()
          conn.commit()
          conn.close()
  #返回电影列表
  return movie_list
  if __name__ == "__main__":
  movies=get_movies(4)
  print (movies)
所遇到问题:
  1. xpath返回的内容为list
    所以我尝试用代码将其转为字符串,如:
 M_name=Movie.xpath('./div/div[2]/div[1]/a/span[1]/text()')
          name=",".join(map(str, M_name))
2.
```

```
import requests
from lxml import etree
import time
import MySOLdh
#定义函数抓取每页前60条商品信息
def get mobile(n):
  #构造每一页的url变化
  url='https://search.jd.com/Search?keyword=%E6%89%8B%E6%9C%BA&enc=utf-
8&qrst=1&rt=1&stop=1&vt=2&cid2=653&cid3=655&page='+str(2*n-1)
  headers = {'authority': 'search.jd.com',
                     'method': 'GET'
                     'scheme': 'https',
                     'referer': 'https://search.jd.com/Search?keyword=%E6%89%8B%E6%9C%BA&enc=utf-
8\&qrst=1\&rt=1\&stop=1\&vt=2\&wq=\%E6\%89\%8B\%E6\%9C\%BA\&cid2=653\&cid3=655\&page=1\&s=58\&click=0', BA\&cid2=653\&cid3=655\&page=1\&s=58\&click=0', BA\&cid2=655\&page=1\&s=58\&click=0', BA\&cid2=655\&page=1\&s=58\&click=0', BA\&cid2=655\&page=1\&s=58\&click=0', BA\&cid2=655\&page=1\&s=58\&click=0', BA\&cid2=655\&page=1\&s=58\&click=0', BA\&cid2=655\&page=1\&s=58\&click=0', BA\&cid2=655\&page=1\&s=58\&click=0', BA\&cid2=655\&page=1\&s=58\&click=0', BA\&cid2=655\&page=1\&s=58\&click=0', BA\&cid2=655\&page=1\&s=58\&page=1\&s=58\&click=0', BA\&cid2=65\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=1\&s=58\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18\&page=18
                     'user-agent': 'Mozilla/5.0 (Windows NT 10.0; WOW64) AppleWebKit/537.36 (KHTML, like Gecko)
Chrome/72.0.3626.119 Safari/537.36',
                     'x-requested-with': 'XMLHttpRequest',
                     'Cookie':'grsc=3; pinId=RAGa4xMoVrs; xtest=1210.cf6b6759; ipLocation=%u5E7F%u4E1C; _irda=5;
mXIh5rrfuDisHSNhZcsJvg; shshshfpa=17943c91-d534-104f-a035-6e1719740bb6-1525571955;
shshshfpb=2f200f7c5265e4af999b95b20d90e6618559f7251020a80ea1aee61500; cn=0;
3 A B 9 D 2 3 F 7 A 4 B 3 C 9 B = Q F O F I D Q S I C 7 T Z D Q 7 U 4 R P N Y N F Q N 7 S 2 6 S F C Q Q G T C 3 Y U 5 U Z Q J Z U B N P E X M X 7 O 3 R 7 S I R B T T J 7 C A X C 4 S 3 I J 4 6 E S B L T N H D C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y C A Y 
37u; ipLoc-djd=19-1607-3638-3638.608841570; __jdu=930036140; user-key=31a7628c-a9b2-44b0-8147-
f10a9e597d6f; areaId=19; __jdv=122270672|direct|-|none|-|1529893590075; PCSYCityID=25;
yJQbvhiwR9BGlunzwowYlldvF0%3D; __jdc=122270672; shshshfp=72ec41b59960ea9a26956307465948f6; rkv=v0700;
__jda=122270672.930036140.-.1529979524.1529984840.85; __jdb=122270672.1.930036140|85.1529984840;
shshshsID=f797fbad20f4e576e9c30d1c381ecbb1_1_1529984840145'
  r = requests.get(url, headers=headers)
  #指定编码方式,不然会出现乱码
  r.encoding='utf-8'
  htmltext = etree.HTML(r.text)
  #定位到每一个商品标签1i
  datas=htmltext.xpath('//li[contains(@class,"gl-item")]')
  #将数据存储到mysq1数据库
  mobile list=[]
  for data in datas:
           conn=MySQLdb.connect(host='localhost',
                                                                     user='dxi'.
                                                                     passwd='a81877568',
                                                                     db='python',
                                                                     charset='utf8')
           cur=conn.cursor()
           array_price =data.xpath('./div/div[3]/strong/i/text()[1]')
           p_price = ",".join(map(str, array_price))
           array_comment =data.xpath('./div/div[4]/a/i/text()')
           p_comment = ",".join(map(str, array_comment))
           array_name = data.xpath('./div/div[4]/a/em/text()')
           p_name = ",".join(map(str, array_name))
           mobile list.append(p name)
           sql="INSERT INTO jd_mobile(m_name,m_price,m_comment) VALUES('%s','%s','%s')"%
(p_name,p_price,p_comment)
           cur.execute(sql)
           cur.close()
           conn.commit()
           conn.close()
  return mobile_list
#定义函数抓取每页后30条商品信息
def get_last(n):
  #获取当前的Unix时间戳,并且保留小数点后5位
  a=time.time()
  b='%.5f'%a
  url='https://search.jd.com/s_new.php?keyword=%E6%89%8B%E6%9C%BA&enc=utf-
20)+'&scrolling=y&log_id='+str(b)
  head={'authority': 'search.jd.com',
                     'method': 'GET',
```

```
'path': '/s_new.php?keyword=%E6%89%8B%E6%9C%BA&enc=utf-
8&grst=1&rt=1&stop=1&vt=2&wq=%E6%89%8B%E6%9C%BA&cid2=653&cid3=655&page=4&s=84&scrolling=y&loq_id=1529828
7495,26480543553,7345757,4483120,6176077,6932795,7336429,5963066,5283387,25722468892,7425622,4768461',
              'scheme': 'https',
              'referer': 'https://search.jd.com/Search?keyword=%E6%89%8B%E6%9C%BA&enc=utf-
8\&qrst=1\&rt=1\&stop=1\&vt=2\&wq=\%E6\%89\%8B\%E6\%9C\%BA\&cid2=653\&cid3=655\&page=3\&s=58\&click=0',
              'user-agent': 'Mozilla/5.0 (Windows NT 10.0; WOW64) AppleWebKit/537.36 (KHTML, like Gecko)
Chrome/72.0.3626.119 Safari/537.36',
              'x-requested-with': 'XMLHttpRequest',
              'Cookie':'qrsc=3; pinId=RAGa4xMoVrs; xtest=1210.cf6b6759; ipLocation=%u5E7F%u4E1C; _jrda=5;
TrackID=1aUdbc9HHS2MdEzabuYEvED1iDJaLwwBAfGBfvIHJZCLWKfwaB KHKIMX9Vi9 2wUakxuSLA09AFtB2U0SsAD-
mXIh5rIfuDiSHSNhZcsJvg; shshshfpa=17943c91-d534-104f-a035-6e1719740bb6-1525571955;
shshshfpb=2f200f7c5265e4af999b95b20d90e6618559f7251020a80ea1aee61500; cn=0;
3 AB9D23F7A4B3C9B = QFOFIDQSIC7TZDQ7U4RPNYNFQN7S26SFCQQGTC3YU5UZQJZUBNPEXMX7O3R7SIRBTTJ72AXC4S3IJ46ESBLTNHD\\ ABSCRIPTION AND ADMINISTRATION ADMINISTRATION ADMINISTRATION ADMINISTRATION ADMINISTRATION ADMINISTRATION ADMINISTRATION ADMINISTRATION ADMINISTRATIO
37u; ipLoc-djd=19-1607-3638-3638.608841570; __jdu=930036140; user-key=31a7628c-a9b2-44b0-8147-
f10a9e597d6f; areaId=19; __jdv=122270672|direct|-|none|-|1529893590075; PCSYCityID=25;
yJQbVhiwR9BGluNZwoWYl1dVF0%3D; __jdc=122270672; shshshfp=72ec41b59960ea9a26956307465948f6; rkv=v0700;
__jda=122270672.930036140.-.1529979524.1529984840.85; __jdb=122270672.1.930036140|85.1529984840;
shshshsID=f797fbad20f4e576e9c30d1c381ecbb1_1_1529984840145'
 r = requests.get(url, headers=head)
 r.encoding = 'utf-8'
 html1 = etree.HTML(r.text)
 datas = html1.xpath('//li[contains(@class,"gl-item")]')
 #将数据存储到mvsql数据库
 mobile_list2=[]
 for data in datas:
       conn=MySQLdb.connect(host='localhost',
                                              user='dxj',
                                               passwd='a81877568'.
                                               db='python',
                                               charset='utf8')
       cur=conn.cursor()
       array_price =data.xpath('./div/div[3]/strong/i/text()[1]')
       p_price = ",".join(map(str, array_price))
       array_comment =data.xpath('./div/div[4]/a/i/text()')
       p_comment = ",".join(map(str, array_comment))
       array_name = data.xpath('./div/div[4]/a/em/text()')
       p_name = ",".join(map(str, array_name))
       mobile_list2.append(p_name)
       sql="INSERT INTO jd_mobile(m_name,m_price,m_comment) VALUES('%s','%s','%s')"%
(p_name,p_price,p_comment)
       cur.execute(sql)
       cur.close()
       conn.commit()
       conn.close()
 return mobile_list2
if __name__=='__main__':
 for i in range(1,2):
       #下面的print函数主要是为了方便查看当前抓到第几页了
       trv:
              print(' First_Page: ' + str(i))
              mobile list1=get mobile(i)
              mobile_list2=get_last(i)
              print(' Finish')
              print(mobile list1)
              print(mobile_list2)
        except Exception as e:
             print(e)
       print('----')
```

部分借鉴了网上的内容

前三十条是直接显示,所以可以直接爬取,后三十为动态加载通过找到对应的API接口,然后构造请求来模拟浏览器。

搭建环境

进入venv环境

创建对应Django文件夹,在对应文件夹下输入命令

1. 创建虚拟环境

python -m venv venv

2.运行文件

venv/Scripts/activate.bat

进入如下图所示界面

₫ 命令提示符

(venv) C:\Users\asus\Desktop\Django\venv\Scripts>cd..

(venv) C:\Users\asus\Desktop\Django\venv>cd..

(venv) C:\Users\asus\Desktop\Django>

安装相应库

1.更新包管理工具pip

 $\hbox{(venv) $C:\Users\asus\Desktop\Django>python -m pip install --upgrade pip } \\$

2. 下载Django与PyMysql

pip install django==2.0
pip install PyMysql

下载的版本是Django2.0与PyMysql0.9.3

可通过pip list查看对应版本

构建项目与管理

创建项目

django-admin startproject Pyspider

创建动态页面

python manage.py startapp Spider

连接mysql数据库

打开settings文件

```
#将Spider添加已安装的项目中
INSTALLED_APPS = [
'django.contrib.admin',
'django.contrib.auth',
```

```
'django.contrib.contenttypes',
'django.contrib.sessions',
'django.contrib.messages',
'django.contrib.staticfiles',
'Spider',
'''省略'''
#修改连接内容
DATABASES = {
'default': {
  'ENGINE': 'django.db.backends.mysql',
  #已创建好的数据库
  'NAME': 'oa'.
  'HOST': 'localhost',
  'PORT': 3306,
  'USER': 'dxi'
  'PASSWORD': 'a81877568',
}
```

修改**项目**的___init__.py 文件并加入如下所示的代码,这段代码的作用是将PyMySQL视为MySQLdb来使用,从而避免Django找不到连接MySQL的客户端工具而询问你:"Did you install mysqlclient?"

```
import pymysql

pymysql.install_as_MySQLdb()
```

尝试使用python manage.py migrate实现数据库迁移,为应用程序创建对应的数据表

发生报错

django.db.utils.ProgrammingError: (1064, "You have an error in your SQL syntax; check the manual that corresponds to your MySQL server version for the right syntax to use near '; SET SESSION TRANSACTION ISOLATION LEVEL READ COMMITTED' at line 1")

查询资料发现可能与我mysql版本有关

在DATABASES中添加了一句'OPTIONS':{'isolation_level':None} 运行成功

```
(venv) C:\Users\asus\Desktop\Django\Pyspider>python manage.py migrate Operations to perform:
Apply all migrations: admin, auth, contenttypes, sessions Running migrations:
Applying contenttypes.0001_initial... OK
Applying auth.0001_initial... OK
Applying admin.0001_initial... OK
Applying admin.0002_logentry_remove_auto_add... OK
Applying contenttypes.0002_remove_content_type_name... OK
Applying auth.0002_alter_permission_name_max_length... OK
Applying auth.0003_alter_user_email_max_length... OK
Applying auth.0004_alter_user_username_opts... OK
Applying auth.0005_alter_user_last_login_null... OK
Applying auth.0006_require_contenttypes_0002... OK
Applying auth.0007_alter_validators_add_error_messages... OK
Applying auth.0008_alter_user_last_name_max_length... OK
Applying auth.0009_alter_user_last_name_max_length... OK
Applying sessions.0001_initial... OK
```

初次运行

```
python manage.py runserver
#运行后进入http://127.0.0.1:8000/
```

django View release notes for Django 2.0



The install worked successfully! Congratulations!

You are seeing this page because DEBUG=True is in your settings file and you have not configured any URLs.

后台管理模型

1. 建立超级用户

python manage.py createsuperuser

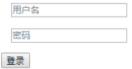
(venv) C:\Users\asus\Desktop\Django\Pyspider>python manage.py createsuperuser
Username (leave blank to use 'asus'): dxj
Email address: 1054242248@qq.com
Password:
Password (again):
Superuser created successfully.

观察数据库发现用户创建成功并且密码加密了

2. 登录后台管理系统

样式原先无法显示

请登录



忘记了您的密码或用户名?

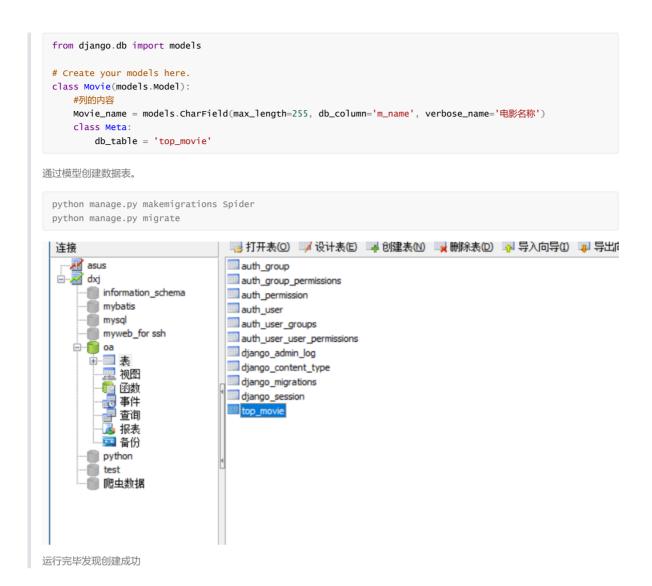
查询大量资料,尝试数遍后发现修改base.html的标签就可以正常显示



3. 创建models

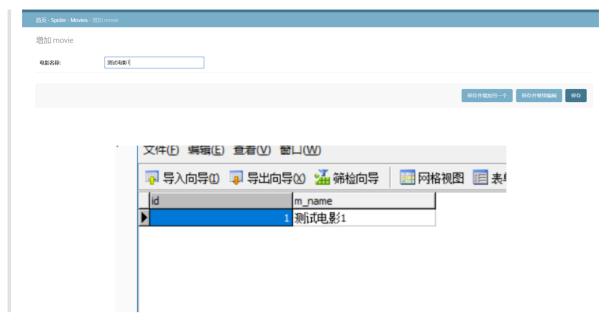
先尝试豆瓣电影top250

编写models文件



注册模型类





管理界面优化

```
from django.contrib import admin
from Spider.models import Movie
class MovieAdmin(admin.ModelAdmin):
list_display = ('id','Movie_name')
search_fields = ('id','Movie_name')
admin.site.register(Movie,MovieAdmin)
  Q [
                                        搜索
                       ▼ 执行 3 个中 0 个被选
  动作 -----
                                                       电影名称
  3
                                                       测试电影3
                                                       测试电影2
  1
                                                       测试电影1
  3 movies
```

页面设计

修改views.py

以豆瓣为例

```
#coding:utf-8
from django.shortcuts import render
from Spider.models import Movie
# Create your views here.
def show_movie(request):
   ctx = {'movie_list': Movie.objects.all()}
   return render(request, 'demo/movie.html', ctx)
```

修改urls.py

```
from django.contrib import admin
from django.urls import path
from Spider import views
urlpatterns = [
path('admin/', admin.site.urls),
 path('movie/', views.show_movie),
```

设计模板页

豆瓣电影

{% for movie in movie_list %}

{{movie.Movie_name }}

```
{{movie.Movie_star}}
      {{movie.Movie_href}}
{% endfor %}
```

结果展示

豆瓣电影

肖申克的救赎

https://movie.douban.com/subject/1292052/

霸王别姬

https://movie.douban.com/subject/1291546/

这个杀手不太冷

https://movie.douban.com/subject/1295644/

阿甘正传

9.4 https://movie.douban.com/subject/1292720/

美丽人生

最终结果

豆瓣

结果之前已经差不多展示了就不再展示

京东

京东手机内容爬取与豆瓣大体类似

在已有环境下流程

创建数据库 通过模型创 模型

(

建数据表 (数据模型 创建视图文 件

(views.py) 创建模板页 (xxx.html)

添加path (urls.py)

展示结果

models.py) 迁移)

结果如下

京东手机

手机名称介绍: vivoZ3 6GB+64GB大内存 领券立减100元

促销活动内容:

手机价格: 1598.00

手机名称介绍: 荣耀8X 千元屏霸 91%屏占比 2000万AI双摄 4GB+64GB 幻夜黑 移动联 通电信4G全面屏, 双卡双待

促销活动内容: 限时优惠1299! 麒麟710处理器, 2000万AI双摄, 人脸+指纹双识别! 荣耀爆品特惠, 选品质, 购荣耀~

手机名称介绍: Apple iPhone XR (A2108) 128GB 黑色 移动联通电信4G, 双卡双待

促销活动内容:【五一假期提前放价,抢券立减400元】小屏经典iPhone7仅售3199元,iPhoneXR低至4799元! 白条12期免息券27

手机价格: 5699.00

总结感想

在做的途中可以说大小bug不断,各种版本不兼容问题等等,所幸的是最终还是完成了。虽然说最后的展示并不好看,也没有做什么 花里胡哨的东西,但是总的过程还是大致上了解了。毕竟这还只是初步的内容,后期会逐步完善,如:

- 1. 爬取图片进行保存
- 2. 将爬虫程序写入Django框架中,而不是独立出去
- 3. 为每条内容添加链接,转入详细介绍的页面
- 4. 融入Ajax内容对电影手机进行评价
- 5. 实现"用户注册"和"用户登录"的功能。
- 6. 尝试使用多线程爬取网页

还算任重道远, 仍需努力, 不过目前就到此为止吧~

OVER~